2026년도 LLM 생성 텍스트 탐지 예측모델 개발 및 시각화

AI개발 수행내역서

과제명	**LLM 생성 텍스트 탐지 예측모델 개발 및 시각화**
담당자	**변운조**

2026년 4 월 03 일

AI개발 수행내용

1. 사업과제 : LLM 생성 텍스트 탐지 예측모델 개발 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

○ ChatGPT, Claude 등 LLM의 발달로 사람이 쓴 것과 구별하기 힘든 고품질의 텍스트 생성이 가능

○ 대학 레포트 대필, 가짜 뉴스 생성, AI를 이용한 스팸 메일 및 피싱 공격 등 텍스트의 출처가 불분명해짐에 따라 사회적 신뢰도 하락

○ 단순히 문장 길이만 보거나 수동으로 확인하는 방식으로는 방대한 양의 AI 텍스트를 걸러내기에 역부족

○ 기계학습 알고리즘을 활용하여, 텍스트 내의 미세한 패턴(단어 빈도, 중요도 등)을 분석해 AI 생성 여부를 수치로 증명

2.2 과제 범위

과제구분		내용
AI	LLM 생성 텍스트 탐지 예측모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA)
		예측모델 선정 및 학습
		평가지표를 활용한 모델 성능 평가
		웹기반 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	LLM 생성 텍스트 탐지 예측모델 개발 및 시각화	웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		예측모델 시각화
		테스트
		통합테스트 및 시운전

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

■ 신뢰도 높은 플랫폼(Kaggle)에서 제공되는 대규모 에세이 데이터셋을 활용하여, 초기 학습에 필요한 정답이 포함된 양질의 데이터를 확보

■ 향후 다양한 LLM에서 생성된 최신 텍스트 데이터를 추가로 수집하고 통합하기에 용이한 텍스트 기반 구조를 선정

○ 예측모델 개발 효율성

■ 텍스트 분류에 강력한 분류기법을 활용하여 높은 성능지표를 도출

■ TF-IDF 벡터화와 불용어 제거 공정을 체계화하여, 핵심 키워드 선별해 학습 속도를 개선

○ 기술 생태계 기여도 및 경제성

■ LLM이 생성한 텍스트가 무분별하게 유통되는 것을 방지하여, 디지털 콘텐츠의 투명성을 높이고 온라인 정보 생태계의 신뢰 회복에 기여

■ AI 생성 텍스트의 특징을 정량화하여 공개함으로써, 향후 더 정교한 탐지 기술이나 반대로 더 인간다운 AI 문장 생성 기술 연구에 기초 자료로 활용

2) AI 예측 분석모델 적용 대상

분석 관리 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
LLM 생성 텍스트 탐지	- 글로벌 에세이 및 웹 콘텐츠 데이터셋	- 텍스트 구조 변수: 문장 길이, 단어 개수, 특수문자 빈도 - 언어 복잡도 변수: 단어 평균 길이, 어휘 다양성 - 문맥적 밀도 변수: 단어 밀도	- 텍스트 생성 주체 판별: 입력된 문장의 AI 생성(1) 및 사람 작성(0) 여부 분류 예측 미래 탐지 가이드라인 제시: 모델의 피처 중요도 분석을 통한 차세대 LLM 텍스트 탐지 핵심 지표 도출

3) AI 분석모델 구축 프로세스

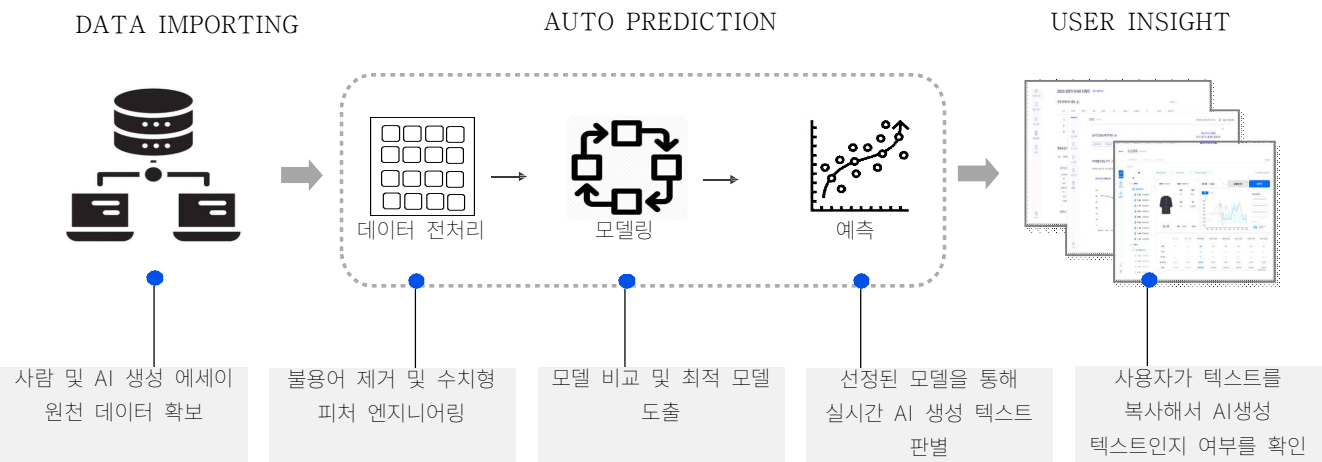

연구개발 주요 결과물

1. 데이터 수집 및 전처리

1-1 데이터 수집

- Kaggle 'DAIGT V2 Train Dataset'
- 사람이 쓴 에세이와 다양한 LLM으로 생성한 텍스트를 결합하여 AI 글쓰기 탐지 모델 학습에 최적화된 데이터셋

text	label	prompt_name	source	RDizzl3_seven
Phones Modern humans today are always on their phone. They are always on their phone	0	Phones and driving	persuade_cor	FALSE
This essay will explain if drivers should or should not be able to use electronic devices while operating a vehicle. Using a phone while driving can cause very bad wrecks, because they are putting themselves and other people at risk. People should not be	0	Phones and driving	persuade_cor	FALSE

[표1. 로우데이터]

1-2 데이터 전처리 및 파생변수 생성

- 원본 텍스트에서 분석 노이즈인 특수문자와 불용어(Stopwords)를 제거하여 데이터의 순수도를 높이는 정제 과정을 수행
- 텍스트 데이터(TF-IDF)만으로는 놓칠 수 있는 문장 전체의 통계적 특징을 수치형 파생변수로 보완함으로써, 모델이 다각도에서 데이터를 입증할 수 있도록 파생변수를 생성

피처명	설명	해석
문장_길이	문장의 전체 길이	글의 전체적인 부피 측정
단어_개수	단어의 전체 개수	단어의 분량 파악
단어_평균길이	문장 길이/단어 개수	단어들이 얼마나 긴지 파악
어휘_다양성	중복 없는 단어 개수/ 전체 단어 개수	얼마나 다양한 단어를 사용한지 파악
단어_밀도	단어의 개수/문장의 길이	문장의 길이 대비 단어의 밀도 파악
특문_개수	특수문자(.,!?)의 총개수	문장 부호 사용 습관 측정

[표2. 파생변수]

- 분석과 연관이 없는 컬럼(source, RDizzl3_seven 등) 3개 삭제

label	clean_text	text_len	word_count	avg_word_ler	lexical_divers	word_density	punc_count
0	phones modern humans today alwa	2029	379	5.353562005	0.525065963	0.186791523	32
0	essay explain drivers able use electro	2141	366	5.849726776	0.469945355	0.170948155	42
0	driving use cellular devices today so	1044	178	5.865168539	0.612359551	0.170498084	13
0	phones driving drivers able use pho	1243	212	5.863207547	0.537735849	0.170555109	20
0	cell phone operation driving ability	1911	332	5.756024096	0.584337349	0.173731031	28
0	cell phone use legal driving causes r	2887	492	5.867886179	0.430894309	0.17041912	43

[표3. 분석데이터]

2. 데이터 분석

2-1 데이터 상관관계

- 피처 간 상관관계를 분석한 결과, 단어_밀도(-0.52)와 단어_개수(-0.26)가 AI 여부를 판단하는 라벨과 유의미한 관계를 맺고 있음을 확인하여 모델의 주요 변수로 채택

[그림1. 상관관계 히트맵]

2-2 탐색적 데이터 분석

- 총 44,868건의 방대한 관측치를 보유하여 모델 학습에 충분한 데이터량을 확보
- 데이터 정제 과정을 통해 결측지가 0%인 데이터셋을 구축

Overview | Alerts 2 | Reproduction

Dataset statistics

Number of variables	11
Number of observations	44868
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	201.9 MiB
Average record size in memory	4.6 KiB

Variable types

Text	2
Categorical	3
Numeric	6

[그림2. EDA 리포트]

- 모델 학습에는 약 4.5만 건의 데이터를 활용했으며, 사람과 AI 데이터의 비중을 적절히 유지하여 특정 클래스에 편향되지 않는 객관적인 탐지 기준으로 학습시킴

라벨
Categorical

Distinct	2
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	2.5 MiB

[그림3. 라벨 데이터 분포]

- 단어 개수 분포를 통해 본 데이터셋이 실제 에세이와 유사한 분량의 텍스트들로 구성되어 있음을 확인했으며, 이를 통해 문맥 파악에 충분한 정보량을 확보함

단어_개수
Real number (ℝ)

Distinct	1064	Minimum	4
Distinct (%)	2.4%	Maximum	1656
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	383.62133	Memory size	350.7 KiB

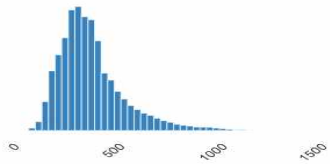

[그림4. 문장길이 데이터 분포]

- 단어 밀도는 매우 안정적인 정규분포를 보이고 있고 이는 글자 수 대비 단어 사용의 일관성을 보여주며, AI와 인간의 미세한 서술 패턴 차이를 수치화하는 핵심 지표로 활용

단어_밀도
Real number (ℝ)

Distinct	35515	Minimum	0.0078740157
Distinct (%)	79.2%	Maximum	0.24014023
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	0.17430544	Memory size	350.7 KiB

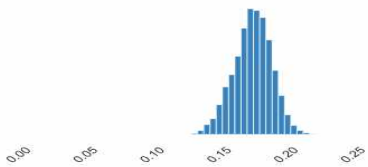

[그림5. 단어밀도 데이터 분포]

- AI(1)는 단어 밀도가 상대적으로 낮고 단어개수가 일정한 분량에 몰려있고, 사람(0)은 단어 밀도가 높게 형성되어 있고 단어개수가 넓게 분포되어 있음. 그래프가 겹치는 면적이 적기 때문에 사람과 AI를 구분 짓는 중요한 피처임을 확인

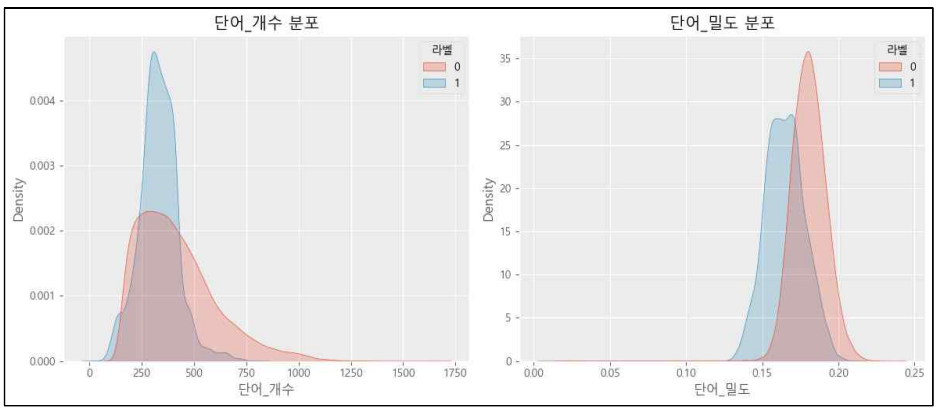

[그림6. 주요데이터의 KDE PLOT]

3. 데이터 학습 및 모델정의

3.1 모델정의 및 예측 수행

- 분석 모델 정의 : 다중선형회귀, 다항회귀, 의사결정나무, 랜덤포레스트

모델명	주요 특징	Accuracy(정확도)	F1-Score	비고
다중 선형 회귀	수치 피처 간 선형 관계 분석	0.44 (R^2)		분류보다는 경향성 파악에 접합
나이브 베이즈	단어 출현 확률 기반 알고리즘	0.95	0.95	최종 선정(속도/정확도)
랜덤 포레스트	다수결 기반 앙상블 모델	0.87	0.83	피처 중요도 파악에 용이
XGBoost	성능 최적화 그래디언트 부스팅	0.88	0.84	높은 정교함, 학습 시간 다소 소요

[표3. AI 탐지 모델별 성능 비교]

3.2 모델학습 및 학습 시각화

- 모델학습은 5개의 피처와 라벨 데이터를 이용하여 진행하였고, 전체 데이터의 80%를 학습시키고 나머지 20%의 데이터를 랜덤시드를 이용하여 테스트 진행

3.2.1 다중 선형 회귀 모델

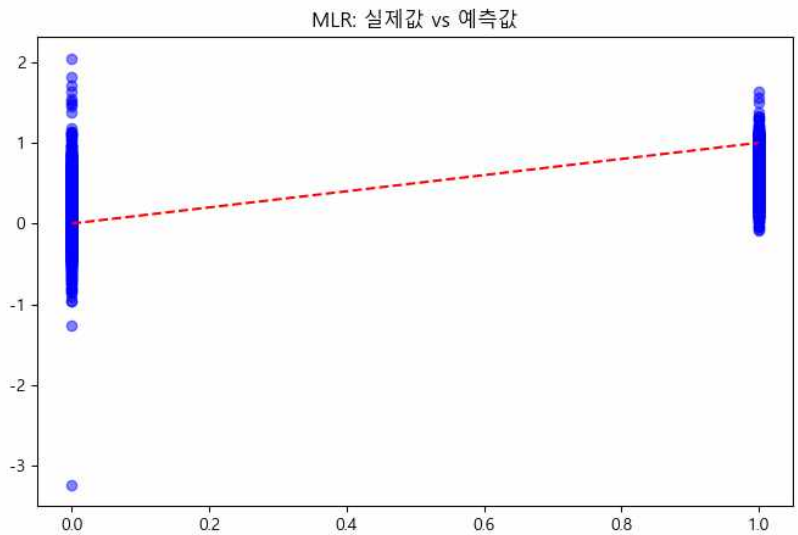

[그림7. 다중 선형 회귀 그래프]

- 피처 간의 경향성을 파악하고자 다중 선형 회귀를 실시한 결과, 인간의 글은 표현의 다양성으로 인해 예측값의 편차가 크지만, AI의 글은 특정 수치 구간에 밀집되어 나타나는 기계적 패턴을 확인
- AI가 일정한 규칙에 따라 문장을 생성하기 때문에 단어 밀도나 문장 길이 같은 지표가 사람보다 훨씬 정형화 되어 있음을 확인
- R^2(결정계수)는 0.44로 전체데이터의 변동성을 약 44% 정도만 설명하고 있고 선형 회귀만으로는 AI와 사람을 완벽히 구분하기에 부족함이 있음을 확인

3.2.2 나이브 베이즈 모델

- 나이브 베이즈는 각 단어가 특정 클래스(인간 vs AI)에 나타날 확률을 독립적으로 계산함 이는 복잡한 문맥보다 사용 단어의 분포 차이가 뚜렷한 LLM 탐지 문제에서 매우 빠르고 강력한 성능을 발휘함
- TF-IDF를 이용하여 모든 문서에 공통으로 나오는 무의미한 단어는 배제하고, AI 특유의 표현 습관이 담긴 핵심 단어에 더 높은 가중치를 부여하여 정확한 분류가 가능
- 수만 개의 단어를 모두 학습하면 모델이 무거워지고 과적합될 위험이 있기 때문에 가장 변별력이 높은 상위 3,000개의 핵심 단어만 추출함으로써 학습 효율성을 극대화하고 탐지 정밀도를 높힘

분류	Prcision(정밀도)	Recall(재현율)	F1-Score	Support(데이터 개수)
인간(0)	0.94	0.98	0.96	5481
AI(1)	0.97	0.90	0.94	3493
accuracy(정확도)			0.95	8974
산술 평균	0.96	0.94	0.95	8974
가중 평균	0.95	0.95	0.95	8974

[표4. 나이브 베이즈 모델 결과]

- 전체 데이터(8,974건)에 대하여 약 95%의 높은 분류 정확도를 기록하여, 나이브 베이즈 모델이 인간과 AI 저작물을 구분하는 데 매우 효과적임을 확인
- 인간(0)과 AI(1) 두 클래스 모두 F1-Score 기준 0.94 이상의 지표를 기록함으로써, 특정 클래스에 편향되지 않은 안정적인 분류 성능을 구축했음을 확인
- 인간(0) 클래스의 재현율이 0.98로 매우 높게 나타나, 실제 인간이 작성한 데이터를 AI로 오판할 확률이 극히 낮음을 확인

3.2.3 랜덤 포레스트

- 인간이 직접 작성한 텍스트 데이터와 생성형 AI를 통해 생성된 텍스트 데이터를 결합한 이진 분류 데이터셋을 사용
- 랜덤 포레스트 모델의 분류 성능 최적화를 위해 주요 하이퍼파라미터인 n_estimators 및 max_depth에 대한 그리드 서치 기반 튜닝을 진행

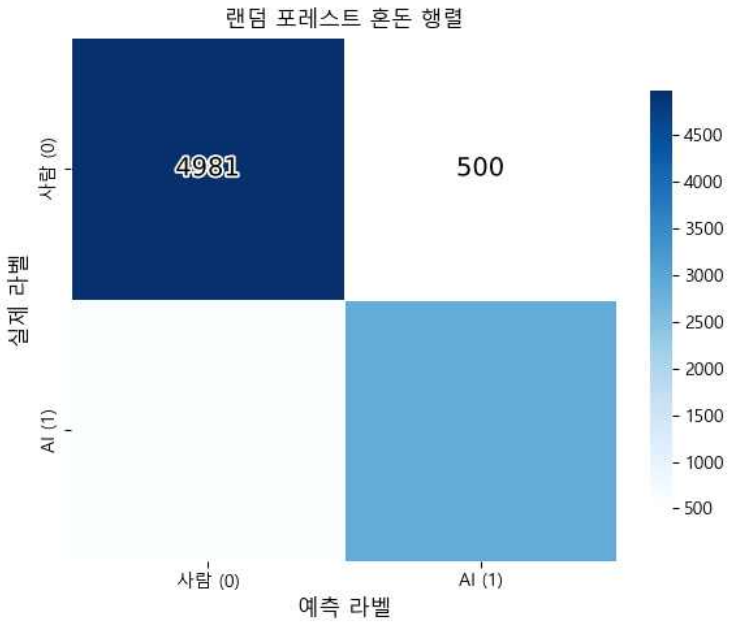

[그림8. 랜덤 포레스트 혼돈 행렬]

- 인간 작성 데이터(5,481건)와 AI 생성 데이터(3,493건)에 대해 약 87%의 정확도(Accuracy)를 기록하며, 두 클래스 간의 유의미한 변별력을 확보함을 확인
- 3-Fold 교차 검증(CV)을 통과함으로써, 특정 샘플에 치우치지 않는 객관적인 분류 체계가 구축되었음을 확인

3.2.3 XGBoost

- XGBoost 모델을 학습시킨 후, 모델 정보 이득이 가장 컸던 지표와 실제 데이터 무작위 섞기(Permutation)를 통해 중요도를 산출

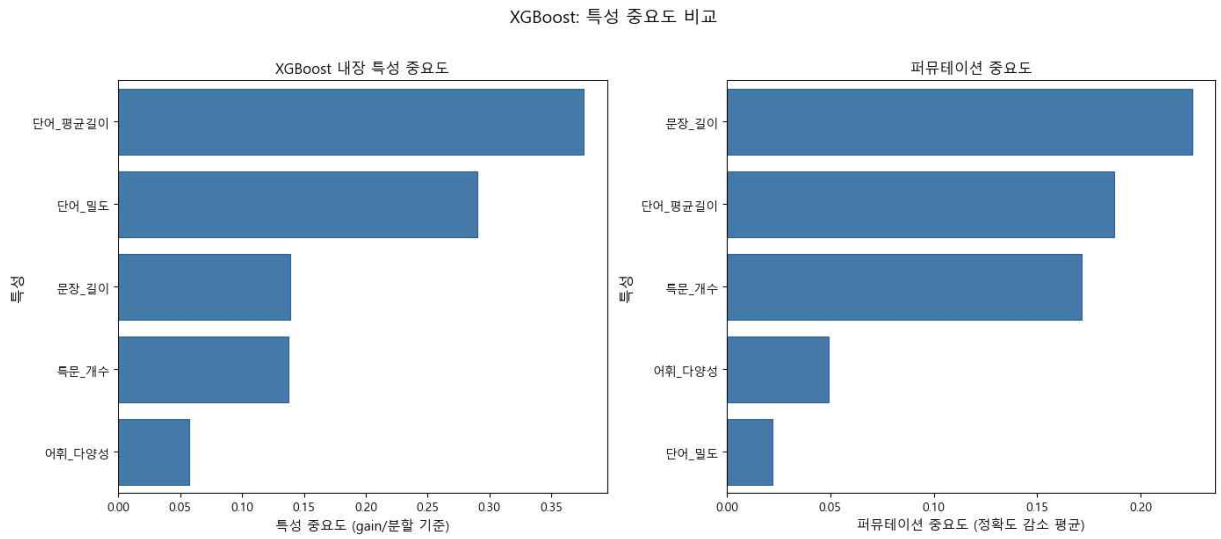

[그림9. XGBoost 중요도]

- 모델은 학습할 때 단어_평균길이를 핵심 기준으로 삼았지만, 실제 데이터를 예측할 때는 문장_길이가 예측의 정확도를 좌우하는 실질적인 가장 중요한 변수임을 확인
- 단어_밀도는 모델 학습 시에는 자주 쓰였으나, 실제 예측 성능에는 기여도가 낮으므로(우측 차트 하단), 향후 모델 최적화 시 우선순위를 낮추어 사용하기를 권장함
- 서비스에 적용할 때는 문장의 전체적인 길이와 단어의 길이를 가장 비중 있는 피처로 관리가 필요
- 현재 모델은 주어진 데이터를 바탕으로 약 88%의 높은 확률로 정답을 맞히고 있음. 이는 앞서 분석한 '문장 길이'와 '단어 평균 길이' 등의 특성들이 분류를 위한 유의미한 정보력을 갖추고 있음을 증명

4. 최종 결과

4.1 테스트 데이터 선정

- ChatGPT(GPT-5.3)에 감정, 기술, 인문학, 역사 등의 다양한 질문을 입력 후 작성한 답변을 선정
- AI가 생선한 텍스트가 아닌, 신뢰도가 있는 매체에 기고한 에세이 위주로 유사한 주제의 글을 선정

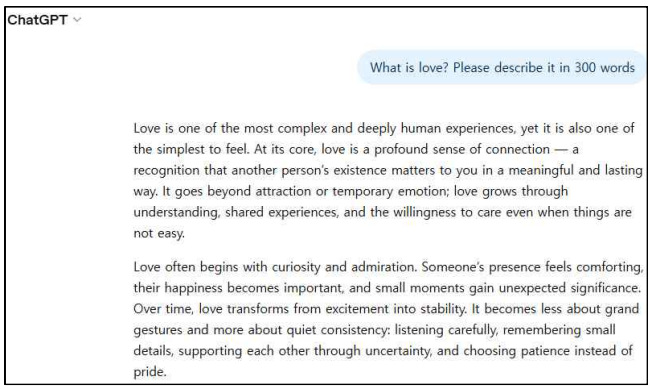

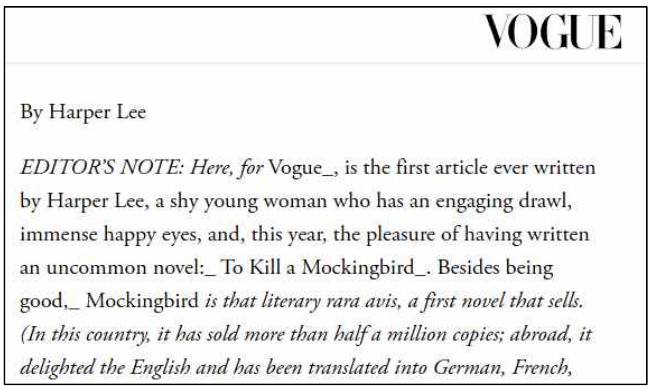

[그림9. 선정한 테스트 데이터]

4.2 테스트 결과

- 비교 대상: GPT 생성 텍스트 vs 실제 기고 에세이 (VOGUE 등)
- 변수 설정: 분석 대상 단어 수 (300, 500, 1000개)
- 관찰 결과: 단어 집합(Vocabulary)의 크기가 커질수록 분류 정확도가 비례하여 상승함

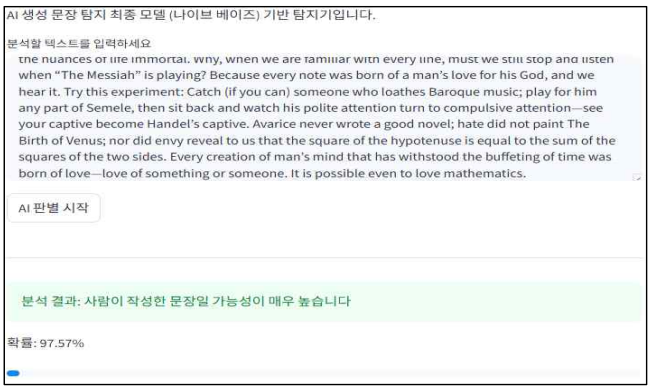

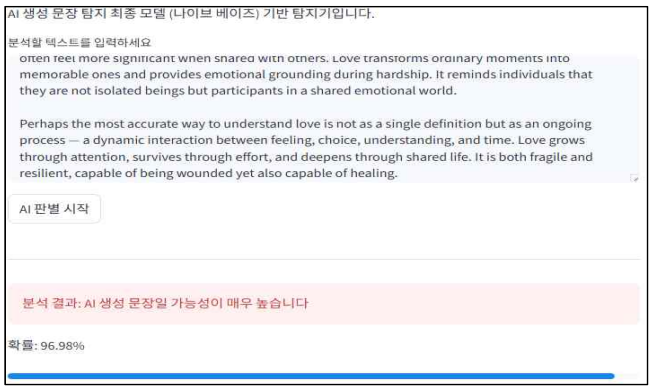

[그림10. 테스트 결과]

- 단어 수를 300에서 1000으로 늘릴수록 확률이 올라감을 확인함
- XGBoost에서 확인된 '문장 구조적 특징(길이, 밀도) 등'과 나이브 베이즈의 '확률적 어휘 분석'이 결합되었을 때, AI와 인간의 글쓰기 스타일을 가장 완벽하게 구분함을 확인
- 향후 모델 고도화 시, 단순 단어 빈도뿐만 아니라 다양한 변수를 추가하여 XGBoost에서 중요도가 높게 나온 파생 변수를 나이브 베이즈에 접목한다면 더욱 강력한 분류 모델 구축이 가능함

5. 결론 및 향후 계획

5.1 모델 개발 결과 요약

- XGBoost 기반 예측 정확도 88.32%를 달성하였으며, 나이브 베이즈 모델을 통한 교차 검증으로 결과의 신뢰성을 확보함. 텍스트 분류에 최적화된 두 알고리즘을 활용하여 AI 생성 문장과 인간 작성 문장 간의 유의미한 차이를 정량적으로 도출함.
- 특성 중요도 분석 결과, 문장 길이와 단어 평균 길이가 분류의 핵심 변수임을 확인함. 나이브 베이즈 실험을 통해 학습 어휘 수가 300개에서 1,000개로 확장될수록 분류 확률이 비례하여 상승하는 데이터 우위성을 입증함

5.2 실무 적용 방안

- GPT 등 LLM을 오남용한 게시글이나 리포트를 실시간으로 탐지하는 솔루션에 적용 가능함. 커뮤니티 관리 도구 내 자동 필터링 모듈로 도입하여 플랫폼 내 콘텐츠의 순도와 신뢰도를 유지하는 데 기여함.
- 어휘 밀도와 문장 구조의 다양성을 지표화하여 사용자 글쓰기의 전문성을 측정하는 피드백 시스템으로 응용함. 학습된 모델을 API 형태로 패키징하여 외부 서비스에서도 실시간으로 분석 결과를 수신할 수 있는 마이크로서비스 구조를 제안함.

5.3 한계점 및 개선 방향

- 현재 모델은 어휘 빈도와 통계적 구조에 의존하므로 심층적인 문맥 파악이나 비유적 표현 해석에는 한계가 존재함. 특정 도메인의 에세이 데이터에 편향될 경우 일상적인 대화체 문장에서 정확도가 저하될 가능성이 있음.
- 통계 기반 모델의 한계를 극복하기 위해 문맥 파악에 특화된 BERT 등 트랜스포머 계열 모델과의 앙상블 기법을 검토함. 향후 뉴스, SNS, 기술 문서 등 다양한 도메인의 데이터를 추가 확보하여 모델의 일반화 성능과 범용성을 강화할 계획임.