2026년도 AI 기반 파이썬 점유율 예측모델 개발 및 시각화

AI개발 수행내역서

과제명	**파이썬 점유율 예측모델 개발 및 시각화**
담당자	**변운조**

2026년 4 월 01 일

AI개발 수행내용

1. 사업과제 : 글로벌 경제·기술 지표를 통한 파이썬 점유율 예측모델 개발 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

○ IT 산업의 중심이 기존 자바 기반 시스템에서 AI 및 데이터 중심의 파이썬 생태계로 급격히 전환됨
○ 나스닥, 엔비디아 주가 및 금리 등 글로벌 경제 지표가 언어 점유율에 미치는 인과관계 입증
○ 2006년부터 2026년까지 약 20년간의 야후 파이낸스, FRED, TIOBE 시계열 데이터 활용
○ AI 하드웨어 성장에 따른 파이썬의 독주 현상을 분석하고 데이터 기반의 기술 스택 예측 모델 구축

2.2 과제 범위

과제구분		내용
AI	AI기반 파이썬 점유율 예측모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA)
		예측모델 선정 및 학습
		RMSE, MAE 등 평가지표를 활용한 모델 성능 평가
		웹기반 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	파이썬 점유율 예측 모델 생성 및 시각화	웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		예측모델 시각화
		테스트
		통합테스트 및 시운전

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- ■ Yahoo Finance API 및 FRED 등 공신력 있는 기관의 공개 데이터베이스 활용
- ■ TIOBE Index 등 전 세계적으로 표준화된 언어 점유율 지표 사용을 통한 객관성 확보
- ■ 경제 지표, 검색량 등 종속변수(언어 점유율)와 상관관계가 뚜렷한 독립변수 포함 여부

○ 예측모델 개발 효율성

- ■ 월별 시계열 데이터의 단순한 구조를 활용하여 선형 회귀 모델 학습 및 평가 과정의 간소화
- ■ 구축된 분석 프레임워크를 통해 다른 프레임워크나 클라우드 서비스 점유율 예측으로의 확장 가능성

○ 기술 생태계 기여도 및 경제성

- ■ 프로그래밍 언어 트렌드 예측을 통해 개발자의 커리어 로드맵 수립 및 학습 비용 최적화 기여
- ■ 기업의 지속 가능한 기술 스택 선정을 지원하여 레거시 시스템 유지보수에 따른 사회적 비용 절감
- ■ IT 경기 변동에 따른 기술 인력 수요를 예측함으로써 산업 전반의 인적 자원 운영 효율성 제고

2) AI 예측 분석모델 적용 대상

분석 관리 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
IT 트렌드 및 파이썬 점유율 분석	- 월별 글로벌 경제 및 IT 기술 지표, 검색량 데이터 - 일자, 주가, 금리, 검색량 외에 프로그래밍 언어 점유율 핵심 변수가 포함된 데이터셋	- 시장·자산 변수 : 나스닥100, 반도체, 성장주ETF 지수 , 금리 - 클라우드·기업 : 아마존 주가, MS 주가, 엔비디아 주가 클라우드(AWS, Azure 등) 검색량 - 언어 생태계 변수 : 자바 점유율	- 파이썬 점유율 - 기술 패러다임 전환 예측 거시경제 및 IT 하드웨어 산업 지표와 언어 생태계 간 상관관계 분석을 통한 미래 기술 스택 수요 예측

3) AI 분석모델 구축 프로세스

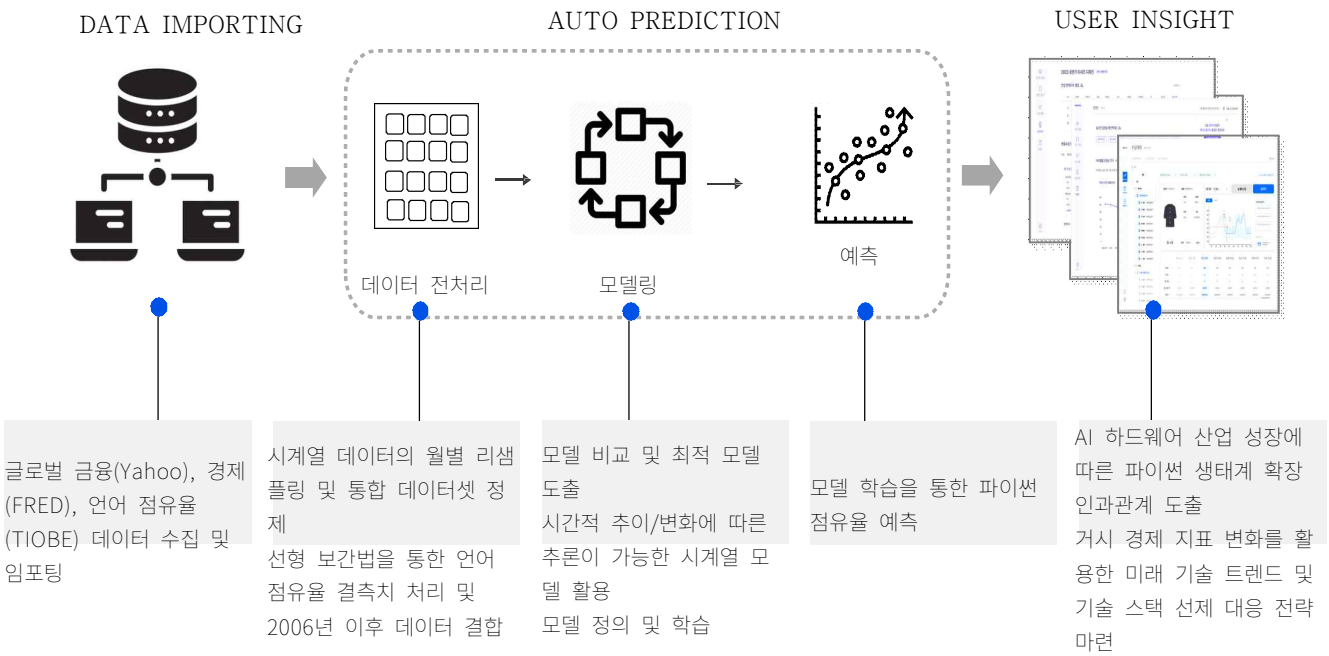

연구개발 주요 결과물

1. 데이터 수집

- 자바, 파이썬 언어 점유율 연별 데이터(엑셀) : 2006년 ~2026년
- 나스닥 100, 반도체, 상장주ETF 지수, 금리 일별 데이터(엑셀) : 2006년 ~2026년
- 엔비디아, MS, 아마존 주가 일별 데이터(엑셀) : 2006년 ~2026년
- 클라우드(AWS,Azure,Google Cloud) 검색량 일별 데이터(엑셀) : 2006년 ~2026년

	자바점유율	파이썬점유율	나스닥100	엔비디아	반도체지수	상장주ETF	금리	클라우드검색	아마존주가	MS주가
2006-02-01	22,96	1,6	1010,71199	0,34669347	535,909639	44,21911	4,49	5	1,94110527	18,7598113
2006-03-01	23,04	1,95	1025,08043	0,38395015	510,014962	44,6538	4,59	5	1,81882608	18,9660691
2006-04-01	22,65	2,13	1057,96369	0,4487904	513,019658	45,00828	4,79	5	1,81621052	18,8999396
2006-05-01	22,57	2,26	1011,66318	0,41601885	493,285862	44,16819	4,94	5	1,70640909	16,3093162
2006-06-01	22,75	1,9	942,233634	0,32706995	449,407541	42,63134	4,99	5	1,7634091	15,7588119
2006-07-01	23,01	1,87	890,153995	0,2998803	413,138598	42,11045	5,24	6	1,662875	16,3886474
2006-08-01	22,68	1,47	924,008691	0,38681005	425,012615	42,67546	5,25	5	1,38984781	17,5660549
2006-09-01	22,56	1,83	994,108002	0,445672	454,242709	44,03408	5,25	5	1,577	18,632564
2006-10-01	22,39	1,75	1033,84727	0,48657657	455,565481	45,68311	5,25	5	1,69654545	19,7930363
2006-11-01	22,54	2,02	1083,28524	0,53726498	471,372397	46,8243	5,25	5	2,02285717	20,653568
2006-12-01	22,5	2,26	1090,61099	0,56398323	474,594856	47,67361	5,24	5	1,965575	20,9271684
2007-01-01	22,14	2,18	1087,0405	0,50993089	466,028004	48,12995	5,25	5	1,87814999	21,5471781
2007-02-01	22,14	2,16	1097,35722	0,50243043	470,065178	48,9819	5,26	5	1,97476315	20,6420918

◯ 데이터 전처리

구분	대상 데이터	원본 상태	전처리 방법	최종상태
주식/경제/검색 지표	나스닥, 금리 등	일 단위	월평균 리샘플링	월 단위
언어 점유율	java, python	연 단위	선형 보간법	원 단위

[전처리 결과표]

기준월	자바점유율	파이썬점유율	나스닥100	엔비디아	반도체지수	상장주ETF	금리	클라우드검색	아마존주가	MS주가
2006-02	22.96	1.6	1011	0.3467	535.9096	44.2191	4.49	5	1.9411	18.7598
2006-03	23.04	1.95	1025	0.384	510.015	44.6538	4.59	5	1.8188	18.9661
2006-04	22.65	2.13	1058	0.4488	513.0197	45.0083	4.79	5	1.8162	18.8999
2006-05	22.57	2.26	1012	0.416	493.2859	44.1682	4.94	5	1.7064	16.3093
2006-06	22.75	1.9	942.2336	0.3271	449.4075	42.6313	4.99	5	1.7634	15.7588
2006-07	23.01	1.87	890.154	0.2999	413.1386	42.1105	5.24	6	1.6629	16.3886

2. 데이터 분석

2.1 데이터 상관관계(Heatmap)

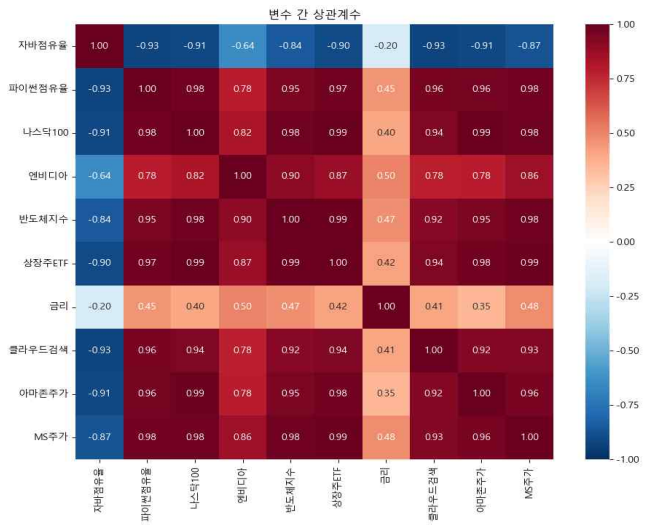

○ 다중공선성을 고려한 핵심변수 선정

본 분석의 핵심 목표인 파이썬 점유율의 변동 추이를 명확히 파악하기 위해, 상관관계가 높은 변수들에 대한 다중공선성 검토를 실시하였습니다. 확인 결과, 나스닥100, 반도체지수, MS주가 등 대부분의 거시경제 지표들이 파이썬 점유율과 0.95 이상의 극도로 높은 상관성을 보였습니다. 이는 지표 간 정보의 중복성이 매우 높음을 의미하므로, 모델의 과적합을 방지하기 위해 상관성이 지나치게 높은 개별 주가 및 지수 데이터는 대표 지수(IT 지수)로 통합하였습니다

○ 새로운 데이터 셋

종속변수: 파이썬 점유율

독립변수:

- 자바점유율: 언어 간 세대교체 흐름 파악용
- 클라우드 검색량: 기술적 환경 변화 대변
- IT 지수: 엔디비아 주가, MS주가, ETF 지수 등을 정규화 후 평균낸 값
- 미국 금리: 자본 유동성 대변

2.2 탐색적 데이터 분석

○ 결측치 및 중복값 통계

Overview | Alerts 5 | Reproduction

Dataset statistics

Number of variables	5
Number of observations	241
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	11.3 KiB
Average record size in memory	48.0 B

Variable types

Numeric	5

- 결측치: 연 단위로 부족했던 언어 점유율 데이터를 선형 보간법을 통해 월 단위로 생성했 으므로, 중간에 비어있는 값이 없습니다
- 중복값: 날짜를 인덱스로 하는 시계열 데이터이기 때문에 한달에 하나의 데이터 포인트만 존재하도록 월별 리샘플링을 수행했기 때문에 동일한 시간대의 데이터가 중복으로 존재 할 수없습니다

○ 주요 변수별 데이터 분포(Histogram)

본 테이블은 다중공선성 해결 및 모델 학습 효율화를 위해 독립변수를 재선정하고 전처리를 완료한 최종 데이터셋입니다. 파이썬 점유율과 독립변수들의 상관 계수를 그래프화 했습니다

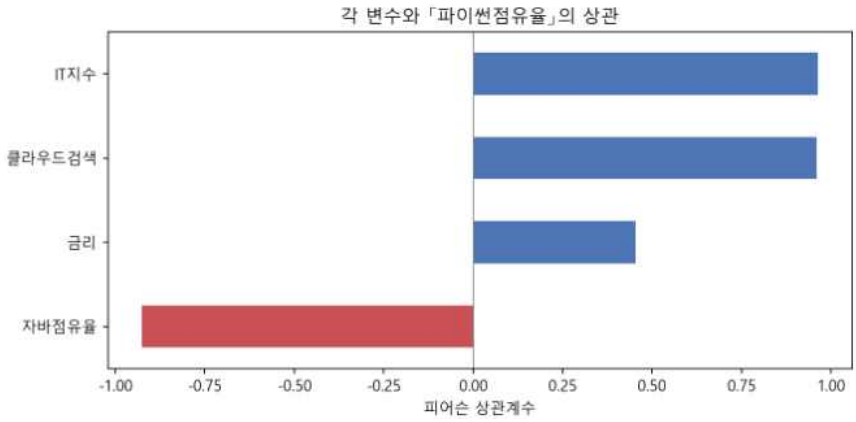

○ 주요 변수별 데이터 분포(Histogram)

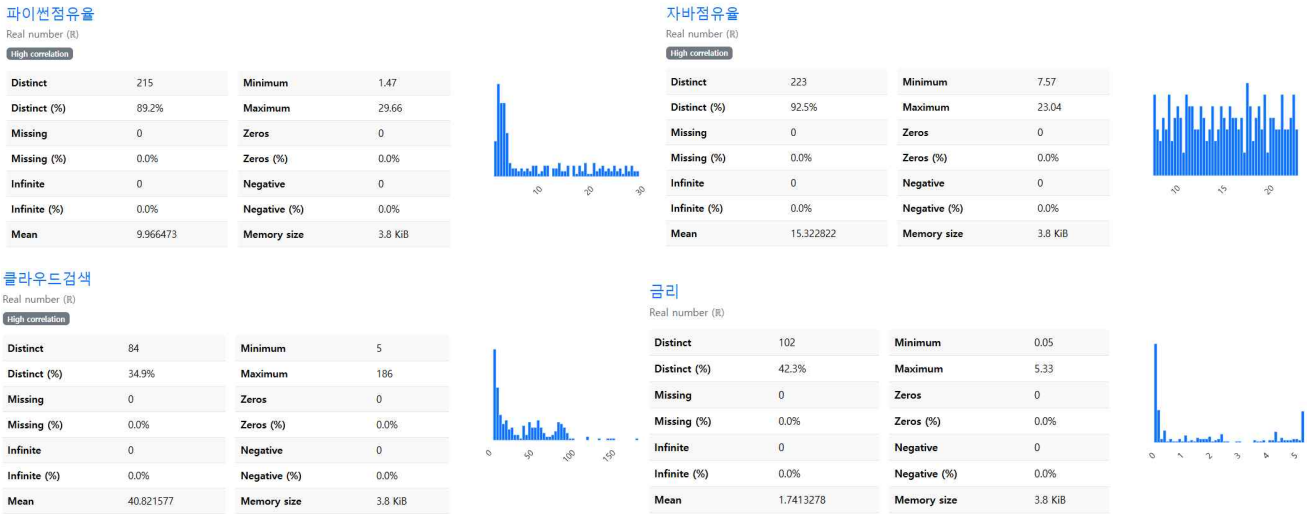

파이썬점유율
Real number (ℝ)
High correlation

Distinct	215	Minimum	1.47
Distinct (%)	89.2%	Maximum	29.66
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	9.966473	Memory size	3.8 KiB

자바점유율
Real number (ℝ)
High correlation

Distinct	223	Minimum	7.57
Distinct (%)	92.5%	Maximum	23.04
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	15.322822	Memory size	3.8 KiB

클라우드검색
Real number (ℝ)
High correlation

Distinct	84	Minimum	5
Distinct (%)	34.9%	Maximum	186
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	40.821577	Memory size	3.8 KiB

금리
Real number (ℝ)

Distinct	102	Minimum	0.05
Distinct (%)	42.3%	Maximum	5.33
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	1.7413278	Memory size	3.8 KiB

3. 데이터 학습 및 모델정의

3.1 모델정의 및 예측 수행

○ 분석 모델 정의 : 다중선형회귀, 다항회귀, 의사결정나무, 랜덤포레스트

분류	다중선형회귀	다항회귀	의사결정트리	랜덤포레스트
종속변수	IT_지수, 금리, 클라우드검색, 자바점유율	IT_지수, 금리, 클라우드검색, 자바점유율	IT_지수, 금리, 클라우드검색, 자바점유율	IT_지수, 금리, 클라우드검색, 자바점유율
독립변수	파이썬 점유율	파이썬 점유율	파이썬 점유율	파이썬 점유율
R-Square	0.9661	0.9954	0.9862	0.9973
MSE	3.0382	0.4102	1.2349	0.2402
RMSE	1.7430	0.6405	1.1113	0.4901
MAE	1.3265	0.5121	0.5265	0.3414

○ 예측 수행

```
# 예측 모델 수행
final_pred = rf_model.predict(input_data)
```

3.2 모델학습 및 학습 시각화

○ 모델 학습

```
# 모델학습
for name, model in models.items():
    if name == "다항회귀(2차)":
        poly = PolynomialFeatures(degree=2)
        X_train_p, X_test_p = poly.fit_transform(X_train), poly.transform(X_test)
        model.fit(X_train_p, y_train)
        y_pred = model.predict(X_test_p)
    else:
        model.fit(X_train, y_train)
        y_pred = model.predict(X_test)

    # 지표 계산
    mse = mean_squared_error(y_test, y_pred)
    rmse = np.sqrt(mse)
    r2 = r2_score(y_test, y_pred)
    results.append({"Model": name, "MSE": mse, "RMSE": rmse, "R2 Score": r2})
    pred_dict[name] = y_pred
```

○ 학습과정 시각화

```
# 6. 결과 시각화 (예측값 vs 실제값)
st.header("3. 예측 결과 시각화")
selected_model = st.selectbox("확인할 모델을 선택하세요", list[str](models.keys()))

fig2, ax2 = plt.subplots(figsize=(10, 4))
ax2.plot(y_test.values, label="실제 점유율", color="black", linewidth=2)
ax2.plot(pred_dict[selected_model], label=f"{selected_model} 예측값", linestyle="--", color="red")
ax2.set_title(f"{selected_model} 예측 성능 분석")
ax2.legend()
st.pyplot(fig2)
```

4. 최종 결과

○ 다중선형회귀

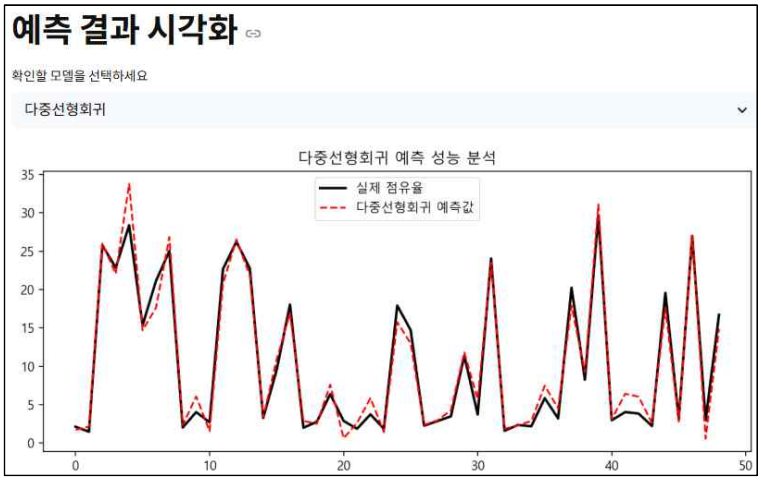

○ 다항회귀

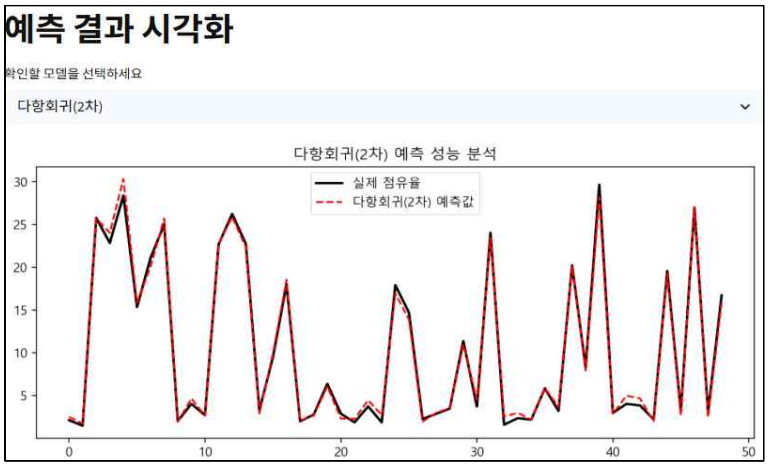

○ 다항회귀

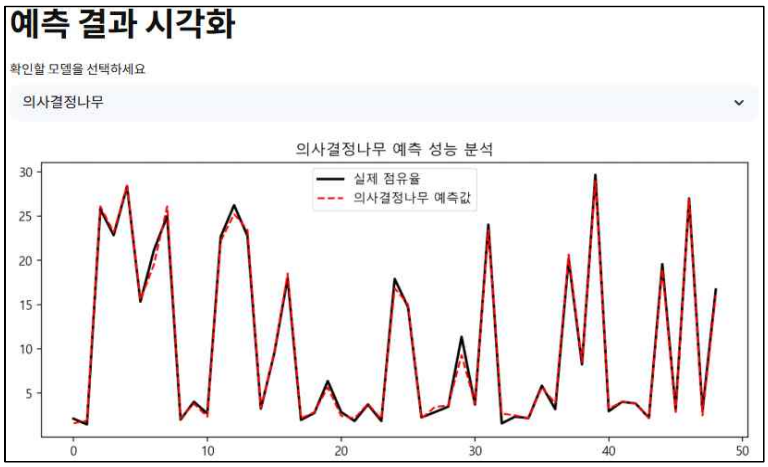

○ 다항회귀

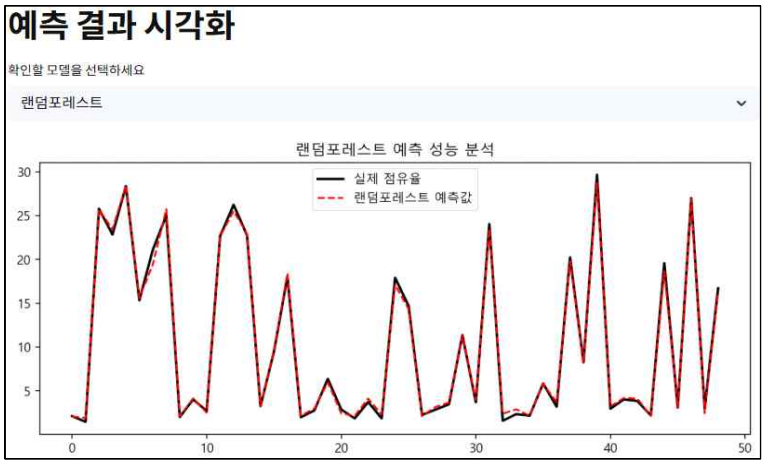

○ 예측모델 선정 – 랜덤 포레스트

- 랜덤포레스트는 R-Square(결정계수)가 0.9973으로 가장 높고 오차(RMSE)가 가장 낮았습니다. 이를 근거로 예측 모델로 선정하였습니다.

5. 결론 및 향후 계획

5.1 모델 개발 결과 요약

- 데이터 가치 입증: 2006년부터 2026년까지의 장기 시계열 데이터를 분석한 결과, 나스닥100·엔비디아 기반의 IT_지수와 클라우드 검색량이 파이썬 점유율 상승의 핵심 동력임을 통계적으로 입증함
- 최적 모델 도출: 다중선형회귀, 다항회귀, 의사결정나무, 랜덤포레스트 4종을 비교 평가한 결과, 랜덤포레스트가 R^2 0.9973, RMSE 0.49라는 압도적인 성능을 기록하며 최종 예측 엔진으로 선정됨
- 상관관계 확인: 자바 점유율과는 강한 음(-)의 상관관계를, IT 산업 지수와는 강한 양(+)의 상관관계를 보이며 기술 패러다임의 세대교체 현상을 데이터로 증명함

5.2 실무 적용 방안

- 기술 스택 의사결정 지원: 본 예측 모델을 통해 도출된 점유율 추이를 기반으로, 기업 및 교육기관에서 차세대 메인 프로그래밍 언어 채택 및 커리큘럼 구성 시 객관적인 근거 자료로 활용 가능함
- IT 경기 선행 지표 활용: 금리 및 IT 지수 변동에 따른 소프트웨어 생태계의 변화를 실시간으로 모니터링하여, 하드웨어 시장의 성장이 소프트웨어 수요로 이어지는 시차를 분석하고 대응 전략을 수립함

5.3 한계점 및 개선 방향

- 데이터 다양성 부족: 현재 주가와 검색량 위주의 지표에서 나아가, GitHub 스타 수, Stack Overflow 질문 빈도 등 실질적인 개발자 커뮤니티의 활성도 데이터를 추가한다면 모델의 정교함을 더욱 높일 수 있음
- 외부 변수 변동성: 러-우 전쟁이나 팬데믹 같은 비정형적 대외 변수(Black Swan)에 대한 영향력은 수치 데이터만으로 예측하기 어려우므로, 뉴스 데이터 분석(NLP)을 병행한 하이브리드 모델 연구가 필요함
- 딥러닝 모델 확장: 향후 커리큘럼에서 다루게 될 RNN(LSTM) 등의 시계열 전문 딥러닝 알고리즘을 추가 적용하여, 현재의 머신러닝 기반 예측보다 장기적인 트렌드 예측력을 강화할 계획임